综合项目任务书

一、项目名称

基于深度学习的无监督工业图像异常检测算法演进综述与性能评测研究

二、项目背景与企业需求分析

1. 产业痛点与技术背景

随着工业4.0和智能制造的快速发展，高端制造领域（如高精度电路板、触控面板、半导体芯片制造等）对产品质量检测的要求越来越高。在这些领域中，工业流水线的生产工艺经过多年的优化和迭代，已经趋于成熟稳定，整体生产良率普遍较高，通常可以达到95%甚至更高的水平。然而，正是在这种高良率的生产环境下，质量检测环节面临着一系列独特的挑战。

缺陷样本的极度稀缺是工业质检中最突出的问题之一。在正常的生产流程中，由于工艺控制严格，产生缺陷的概率本身就非常低，这导致缺陷样本的数量极其有限。以本项目合作企业征图Focusight的触控面板产线为例，在实际的批量生产过程中，缺陷样本可能只占总产量的1%甚至更低。更严重的是，这些少量的缺陷样本往往需要经验丰富的质检人员进行人工筛选和标注，不仅耗时耗力，而且需要深厚的专业知识，导致标注成本非常高昂。此外，某些特殊类型的缺陷可能几个月甚至几年才会出现一次，这使得收集足够数量的缺陷样本变得几乎不可能。

缺陷形态的多样性以及大量未知缺陷的存在，给传统的检测方法带来了巨大挑战。工业产品的缺陷类型千变万化，既包括划痕、污渍、变形、断裂等常见的表面缺陷，也包括内部结构异常、材料成分偏差等难以直观观察的隐性缺陷。更复杂的是，实际生产中还存在大量在训练阶段无法预见的"长尾"缺陷类型，这些缺陷可能在产品生命周期的任何阶段突然出现，且形态各异、特征不明显。传统的基于规则和模板匹配的检测方法在面对这种高度多样化的缺陷时，往往难以建立全面覆盖所有缺陷类型的检测模型。

传统有监督检测方法的局限性同样日益凸显。基于深度学习的视觉检测方法虽然在许多领域取得了显著成效，但这类方法高度依赖海量的已标注缺陷样本来训练模型。在面对新出现的缺陷类型或产线分布变化（如更换原材料、调整工艺参数、环境光照变化等）

时，已训练的模型往往表现出严重的泛化能力不足，需要重新收集样本并进行代价高昂的模型重训练。这种对大量标注数据的依赖与工业场景中缺陷样本稀缺的现实形成了尖锐矛盾，严重制约了智能质检技术在工业领域的推广应用。

2. 无监督检测的优势与适用性

针对上述工业质检中的痛点问题，无监督异常检测技术近年来受到了学术界和工业界的广泛关注。与传统的有监督方法相比，无监督异常检测具有显著的优越性，特别适合工业场景的实际需求。

无监督异常检测的核心思想是在训练阶段仅使用正常样本，通过深度学习模型学习正常产品的外观特征、纹理模式和结构分布规律。在模型训练完成后，当输入测试样本时，模型能够计算该样本与已学习的"正常模式"之间的偏离程度，偏离程度越大则异常分数越高，从而实现对异常样本的检测和定位。这种方法的最大优势在于完全摆脱了对缺陷样本的依赖，只需要收集正常生产状态下的产品图像即可进行模型训练，极大地降低了数据准备的难度和成本，与工业生产中高良率、缺陷稀少的实际数据分布高度契合。

此外，无监督异常检测方法对未知缺陷类型具有更强的适应性和泛化能力。由于模型学习的是正常样本的分布特征而不是特定缺陷的模式，因此理论上能够检测出任何与正常模式不符的异常情况，无论这种异常在训练阶段是否出现过。这种特性在工业应用中具有重要价值，因为生产线上可能出现各种难以预料的异常状况，而企业不可能为每一种可能的缺陷都准备充足的训练样本。

从技术发展的角度来看，近年来无监督异常检测领域涌现出大量创新性研究成果，包括基于深度重构的方法、基于特征分布建模的方法、基于自监督学习的方法以及基于预训练大模型的方法等，这些方法的不断演进为工业质检提供了丰富的技术选择。大量实验研究表明，在MVTec AD等权威基准数据集上，先进的无监督异常检测方法已经能够达到甚至超过部分有监督方法的性能水平，展现出巨大的应用潜力。

3. 本项目核心挑战与技术难点

尽管无监督异常检测方法在理论上具有显著优势，但在实际项目落地过程中仍然面临诸多技术挑战，需要深入研究和解决。

极端的数据约束条件是本项目面临的首要挑战。根据征图Focusight企业的实际需求和项目要求，在模型训练阶段仅能获取正常样本，且训练样本的数量被严格限制在150张以内。这一约束条件极大地增加了算法设计和模型训练的难度：有限的训练样本可能导致模型对正常模式的建模不够充分，影响异常检测的准确性；而小样本条件下的模型也容

易出现过拟合现象，泛化能力不足。因此，如何在极少量的训练样本条件下保证模型的学习效果和鲁棒性，是需要重点攻克的技术难题。

小样本条件下的算法性能变化及鲁棒性分析是本项目的核心研究内容之一。不同类型的无监督异常检测方法对小样本条件的敏感程度可能存在显著差异。基于预训练特征的方法可能由于ImageNet预训练权重的存在而在小样本条件下表现相对稳定；基于自监督学习的方法可能需要较多的训练样本来学习有效的判别边界；基于重构的方法则可能面临重构质量不足的问题。需要系统地对比分析不同方法在小样本条件下的性能变化规律，为企业选择合适的技术路线提供科学依据。

多维度评估体系的设计与实现也是本项目的重要挑战。工业异常检测任务通常需要同时评估两个层面的性能：图像级异常检测能力（判断整张图像是否包含缺陷）和像素级异常定位能力（精确标定缺陷区域的位置和范围）。这需要设计和实现包含AUROC、AUPR、Pixel-AUROC、PRO等多个指标的综合评价体系，并开发相应的评测代码和可视化工具。其中，PRO指标的计算涉及连通域分析和区域重叠度计算，实现起来具有一定的技术复杂度。

此外，真实工业数据与公开基准数据集之间存在差异，如何将公开数据集上验证有效的算法迁移到企业真实场景中并保持良好的性能，也是本项目需要解决的关键问题。企业数据可能存在图像质量不稳定、背景复杂、光照变化大等实际问题，需要针对性地进行数据预处理和算法调优。

三、技术路线与研究内容

模块一：无监督异常检测方法调研与理论分析

本模块需要系统性调研并分析主流无监督工业异常检测技术路线，从以下4类方向中完成其中3类（4选3）。

基于重构的方法以AutoEncoder、VAE、AnoGAN为代表，利用编码器-解码器架构学习正常样本的压缩表示，通过重构误差判定异常，原理直观，但对复杂纹理的重构效果有限。基于特征建模的方法以PaDiM、PatchCore、SPADE为代表，利用ImageNet预训练网络提取多尺度特征，构建正常样本特征库，通过距离度量检测异常，无需单独训练，是目前工业界的主流方案。基于自监督学习的方法以CutPaste、DRAEM、NSA为代表，在正常样本上合成伪异常（如剪切粘贴、噪声叠加），训练判别网络，需要训练过程，但可学习更鲁棒的判别边界。基于预训练大模型的方法以WinCLIP、AnomalyCLIP、

VAND 2.0为代表，利用CLIP等多模态大模型的零样本或少样本能力，通过文本-图像对齐实现异常检测，是2023年后的新兴方向，对未知缺陷泛化能力强，但计算开销较大。

基于项目周期与企业落地需求，建议选择特征建模类（PatchCore/PaDiM）、自监督类（DRAEM/CutPaste）与重构类（AE/VAE）的组合。该方案覆盖经典到主流方法，工程实现成熟，且便于在150张小样本条件下快速验证。预训练大模型方法可作为后续扩展方向。

模块二：数据集构建与数据工程

数据工程是整个项目的基础环节，直接影响后续算法的训练效果和评测的可靠性。这部分工作主要分为两个层面：公开数据集的准备和企业数据集的适配处理。

在公开数据集方面，本项目主要使用MVTec AD数据集，这是目前工业异常检测领域最权威的基准数据集。该数据集由Bergmann等人于2019年在CVPR会议上发布，包含15个类别（5种纹理类如地毯、网格、皮革等，10种物体类如螺丝、牙刷、晶体管等），共计5,354张高分辨率图像，每张图像都配有像素级的异常标注，涵盖了划痕、污渍、断裂、变形等多种缺陷类型，非常适合用于算法的基准测试。此外，还会考虑使用VisA数据集作为补充验证，该数据集由Zou等人于2022年发布，包含12个子集、10,821张图像，覆盖PCB、胶囊等多种工业场景，可以进一步验证算法的泛化能力。

企业数据集的处理是更具挑战性的工作。征图提供的触控面板原始图像往往存在格式不统一、分辨率不一致、背景干扰多等问题。需要开发一套完整的数据清洗与转换流程：对原始图像进行格式统一化处理，将所有图像转换为标准格式；进行尺寸归一化，根据算法需求调整图像分辨率；进行背景过滤，去除与检测无关的区域；进行数据增强处理，包括随机旋转、翻转、裁剪等操作；最终将处理后的数据集重构为符合MVTec AD结构的标准格式，便于与公开数据集进行横向对比。需要特别指出的是，本项目有一个严格的技术约束：训练阶段仅能使用正常样本，且数量不得超过150张，因此需要在代码层面实现训练集规模控制逻辑，通过随机采样模块确保每次训练抽取的正常样本数不超过上限。

模块三：算法复现与性能评测

算法复现与性能评测是本项目的核心工作，需要在理论理解的基础上完成算法的工程实现、调优和系统性的性能评估。工业异常检测任务通常需要从两个维度进行评估：图像级异常检测和像素级异常定位。图像级检测关注的是模型能否正确判断一张图像是否包含缺陷，主要使用AUROC和AUPR两个指标，其中AUROC是ROC曲线下面积，衡量模型在不同阈值下的分类性能，不受类别不平衡影响，在Bergmann等人2021年发表于

International Journal of Computer Vision的论文中被广泛采用；AUPR是精确率-召回率曲线下面积，更适用于正负样本极度不平衡的场景。像素级定位评估的是模型对缺陷区域的定位精度，主要使用Pixel-AUROC和PRO两个指标，Pixel-AUROC计算像素级别的ROC曲线下面积，而PRO（Per-Region Overlap）则是一种更关注区域整体定位准确性的指标，它平等对待不同大小的异常区域，通过计算预测区域与真实区域的重叠度来评估定位效果。

在算法复现方面，需要针对选定的3类方法分别开展工作。对于基于重构的方法（如AutoEncoder、VAE），需要设计合适的编码器-解码器网络结构，选择损失函数（如MSE、SSIM等），调整网络深度和隐藏层维度以优化重构效果，这类方法虽然原理直观，但在复杂纹理上的重构效果有限。对于基于特征建模的方法，根据Defard等人2021年在ICPR会议上发表的PaDiM论文和Roth等人2022年在CVPR会议上发表的PatchCore论文，需要利用ImageNet预训练的ResNet或WideResNet作为特征提取器，构建多尺度的特征记忆库，实现高效的最近邻搜索算法，PatchCore还需要实现核心集采样算法以降低内存占用。对于基于自监督学习的方法，根据Li等人2021年在CVPR会议上发表的CutPaste论文和Zavrtanik等人2021年在ICCV会议上发表的DRAEM论文，需要实现伪异常的合成逻辑，CutPaste通过剪切粘贴的方式合成异常，而DRAEM则使用Perlin噪声生成器来产生随机形状的模拟异常，然后设计判别网络结构进行训练。

在实验验证环节，需要在MVTec AD基准数据集上完成基准测试，获得各类算法的标准性能指标；然后在征图提供的企业真实数据集上验证算法的有效性；在150张小样本条件下重复上述实验，分析各类算法在数据稀缺场景下的性能变化和鲁棒性表现；最后从检测精度、定位能力、推理速度、内存占用等多个维度进行横向对比，形成完整的方法评估报告。

模块四：可视化验证平台开发

为了便于课题验收和结果展示，需要开发一套交互式的Web可视化验证平台。该平台虽然不用于企业实际生产部署，但能够直观地展示不同算法的检测效果和定位能力，是项目汇报和成果演示的重要支撑。

平台的功能设计包括以下几个模块。训练样本选择与管理模块支持用户从本地或预设路径加载训练图像，可视化展示训练集构成，并提供样本筛选和预览功能。模型训练模块支持三种算法的选择和切换，实时展示训练过程中的损失曲线、学习率变化等关键指标，记录训练日志并支持导出。模型推理模块支持单张图像和批量图像的异常检测推理，展示推理耗时和内存占用等性能指标。结果可视化模块是平台的核心功能，需要将原始输入图像与模型输出的异常热力图进行并排展示，热力图以颜色深浅表示异常分数的高低，直观展示模型对缺陷区域的聚焦能力，同时支持检测结果与真实标注的对比展

示。模型对比模块支持不同算法在相同测试样本上的结果对比，便于直观评估各方法的优劣。在技术实现上，前端采用Web界面实现图像展示和交互操作，后端使用Python实现算法推理接口，通过RESTful API进行前后端通信。平台需要支持离线脱机运行，确保在没有外网环境的情况下也能正常演示。在工程实现过程中，需要注意模型权重的加载效率、推理结果的缓存管理、大图展示的内存优化等问题，确保平台的响应速度和用户体验。

说明：该平台主要服务于课题验收和结果可视化展示，企业实际部署将采用集成度更高的后端方案。

四、预期交付成果

1. 学术综述与选型分析报告

本项目将撰写一份详细的学术综述与选型分析报告，系统性地梳理无监督工业图像异常检测领域的技术发展脉络和最新研究进展。报告内容将涵盖以下几个主要部分：技术背景与问题定义，阐述工业异常检测的应用场景、技术挑战以及无监督学习的必要性；技术路线综述，详细介绍基于重构、基于特征建模、基于自监督学习和基于预训练大模型四大技术方向的原理、代表性算法和发展历程；算法原理深度解析，对选定的3类代表性算法（如PaDiM/PatchCore、DRAEM/CutPaste、AutoEncoder/VAE等）进行数学原理、网络结构、损失函数和推理流程的深入剖析；实验对比分析，基于MVTec AD基准数据集和企业真实数据集的实验结果，从图像级检测精度（AUROC、AUPR）、像素级定位精度（Pixel-AUROC、PRO）、推理速度、内存占用等多个维度进行横向对比；企业选型建议，结合征图Focusight企业的实际产线需求和技术约束条件，给出算法选型的具体建议和实施路径。该报告旨在为企业提供一份具有参考价值的技术文档，帮助企业技术团队深入理解无监督异常检测技术的现状和发展趋势，为后续的技术选型和系统开发提供科学依据。

2. 工程化代码仓库

本项目将交付一套完整、规范、可复现的工程化代码仓库，采用模块化设计，结构清晰，注释完整，便于后续维护和扩展。代码仓库的主要组成部分包括：数据集处理模块，实现公开数据集（MVTec AD、VisA）的自动下载、解析和预处理功能，以及企业数据的清洗、增强和格式转换功能，特别包括训练集规模控制逻辑的实现；算法实现模块，包含选定的3类无监督异常检测算法的完整PyTorch实现，每类算法都包含网络结构

定义、训练脚本、推理脚本和配置文件；评测指标模块，实现AUROC、AUPR、Pixel-AUROC、PRO等核心评测指标的计算，以及结果可视化和报表生成功能；工具函数模块，提供日志记录、模型保存与加载、可视化辅助等通用功能。所有代码都将遵循PEP8编码规范，提供详细的README文档说明安装步骤、使用方法和目录结构，确保代码的可读性和可复现性。此外，代码仓库还将包含预训练模型权重文件（如有）和示例数据，方便企业技术团队快速上手验证。

3. 可视化验证平台（原型系统）

本项目将开发一套功能完善的Web可视化验证平台作为原型系统，采用前后端分离的架构设计，前端使用HTML/CSS/JavaScript实现用户交互界面，后端使用Python Flask或FastAPI框架提供RESTful API服务。平台的核心功能包括：训练数据管理功能，支持用户上传、预览、筛选训练样本，可视化展示训练集的数据分布和统计信息；模型训练功能，提供友好的界面让用户选择算法类型、配置超参数、启动训练任务，并实时展示训练过程中的损失曲线、学习率变化等关键指标；模型推理功能，支持单张图像上传和批量图像推理，展示每张测试图像的异常分数、推理耗时和内存占用；结果可视化功能是平台的核心亮点，采用并排展示的方式同时显示原始输入图像、模型输出的异常热力图（使用颜色映射表示异常分数的高低）以及像素级的异常分割掩码，支持对比查看不同算法在同一张测试图像上的检测结果；模型对比功能支持同时加载多个训练好的模型，在相同的测试集上进行批量推理，并生成对比报表和可视化图表。该平台支持完全离线运行，所有数据和模型都存储在本地，确保数据安全性。平台的开发将为课题验收提供直观的演示手段，同时也为企业评估不同算法的实际效果提供便利工具。

五、项目进度安排

周次	日期区间	研究阶段	核心任务
第2-3周	3.09 - 3.22	理论调研与开题	深入分析企业需求，查阅无监督异常检测相关文献，确定3种代表性算法，完成开题报告
第4-5周	3.23 - 4.05	数据工程与基础环境	搭建深度学习环境，解析企业数据集，完成数据清洗与标准化，实现训练集规模控制逻辑
第6-8周	4.06 - 4.26	算法基线构建	完成基于重构和特征建模两类方法的复现与调试，输出基础评测指标

周次	日期区间	研究阶段	核心任务
第9-11周	4.27 - 5.17	进阶方法与对比实验	完成自监督方法的复现，开展三类方法的横向对比与消融实验
第12-13周	5.18 - 5.31	可视化平台开发	开发Web交互式验证系统，实现模型封装、前端展示与后端推理的完整链路
第14-15周	6.01 - 6.14	实验论证与报告撰写	综合分析实验数据，撰写技术报告，总结各方法在工业场景下的适用性
第16-17周	6.15 - 6.28	结题与答辩	代码审核与规范化，制作答辩PPT，完成项目答辩与成果归档

六、项目验收标准

1. 算法覆盖度要求

本项目要求从4类技术路线（重构类、特征建模类、自监督类、预训练大模型类）中选择3类完成实现，每类至少实现一种代表性算法。具体而言，重构类可选择AutoEncoder或VAE等基于编码器解码器架构的算法；特征建模类可选择PaDiM或PatchCore等基于预训练特征和记忆库的算法；自监督类可选择CutPaste或DRAEM等基于伪异常合成的算法。每类算法的实现需要包含完整的网络结构定义、训练流程、推理流程和配置文件，确保算法能够独立运行并达到论文中报告的相近性能水平。算法实现需要遵循模块化设计原则，代码结构清晰，注释完整，便于后续维护和扩展。

2. 评测完整性要求

项目需要在两个数据集上均完成实验并输出完整的评测指标。在MVTec AD基准数据集上进行测试时，该数据集包含15个类别，需要输出每个类别的图像级AUROC和像素级AUROC，以及整体平均指标。在征图Focusight提供的企业真实数据集上进行测试，需要验证算法在真实工业场景下的有效性。评测指标需要包括图像级检测指标（AUROC、AUPR）和像素级定位指标（Pixel-AUROC、PRO）共四项核心指标，每个指标都需要有详细的计算过程和可视化结果。评测代码需要独立封装，便于复用和验证。

3. 小样本验证要求

考虑到企业实际应用中训练样本稀缺的约束条件，本项目要求严格验证算法在不超过150张正常样本条件下的性能表现。需要在MVTec AD数据集的每个类别上随机采样不超过150张正常图像作为训练集，然后与使用全部正常样本训练的结果进行对比分析。需要绘制性能随训练样本数量变化的曲线图，分析不同算法在小样本条件下的鲁棒性差异。对于企业数据集，同样需要测试在150张以内正常样本条件下的检测效果，并与公开数据集的结果进行横向对比，分析数据分布差异对算法性能的影响。

4. 可视化验证平台功能要求

可视化验证平台需要具备完整的功能模块以支持算法的演示和验证。训练样本选择模块需要支持图像的上传、预览、筛选和数据集构建；模型训练模块需要支持多种算法的切换、超参数配置、训练过程监控和日志记录；模型推理模块需要支持单张和批量图像的推理，展示推理时间和资源占用；结果可视化模块需要以并排方式展示原始图像、异常热力图和分割掩码，支持对比查看；模型对比模块需要支持多个模型在相同样本上的结果对比和性能报表生成。平台需要能够在离线环境下独立运行，界面友好，响应速度快，无明显卡顿或崩溃现象。

5. 文档与代码交付要求

项目最终需要交付完整的文档和代码资料。代码仓库需要包含所有算法实现、数据处理脚本、评测代码和可视化平台代码，代码需要遵循PEP8规范，附带详细的README文档说明安装步骤和使用方法。技术报告需要包含项目背景、技术路线、算法原理、实验设计、结果分析和结论建议等内容，报告格式规范，图表清晰，参考文献完整。答辩材料需要包括演示PPT和演示视频，能够清晰地展示项目成果和技术亮点。所有交付物需要经过测试验证，确保能够正常运行和复现报告中的实验结果。